

Relatório 8 - Prática: Web Scraping com Python p/ Ciência de Dados (II)

Igor Carvalho Marchi

1. Introdução

A aula apresenta conceitos importantes sobre coleta de dados web, ou raspagem web, que é uma forma de mineração que permite a extração de dados de sites da web convertendo-os em informação estruturada para posterior análise. O tipo mais básico de coleta é o download manual das páginas, copiando e colando o conteúdo, e isso é fundamental em Ciência de Dados.

2. Desenvolvimento

2.1 Basic scraping project

Na primeira parte do trabalho, foi desenvolvido um script em Python utilizando a biblioteca BeautifulSoup, pertencente ao pacote bs4, com o objetivo de realizar a leitura e a extração de informações de um arquivo HTML local.

Hello, Start Learning!




Imagem 1 - O site do html usado na aula.

Inicialmente, o arquivo home_aula.html foi aberto em modo de leitura, permitindo o carregamento completo do seu conteúdo em formato de texto. Em seguida, esse conteúdo foi processado por meio da classe BeautifulSoup, utilizando o parser lxml, que possibilita a navegação e a análise da estrutura do documento HTML.

Após a criação do objeto BeautifulSoup, foram identificados todos os elementos <div> que possuem a classe card, os quais representam os cartões de cursos presentes na página. Para cada um desses cartões, o código percorreu sua estrutura interna, extraíndo o nome do curso a partir da tag <h5> e o valor do curso a partir do texto contido na tag <a>.

Por fim, as informações coletadas nome e preço dos cursos, foram exibidas no terminal de forma organizada, demonstrando a aplicação prática de técnicas de web scraping em arquivos HTML estáticos para obtenção automatizada de dados.




imagem 2 - Fluxograma do código 1.

2.2 scraping a real website

O código desenvolvido tem como objetivo realizar a coleta automática de vagas de emprego para a linguagem Python no site TimesJobs, utilizando as bibliotecas requests e BeautifulSoup. O programa solicita ao usuário a inserção de uma habilidade com a qual ele não possui familiaridade e, a partir disso, filtra as vagas que não exigem essa habilidade, salvando as informações relevantes em arquivos de texto.




Imagem 3 - Site TimesJobs

Entretanto, durante a execução, foi observado que o código não funcionava corretamente devido a uma alteração na estrutura do site. Atualmente, o TimesJobs utiliza JavaScript para carregar dinamicamente o conteúdo das vagas, o que impede que o BeautifulSoup acesse os dados desejados, uma vez que essa biblioteca trabalha apenas com HTML estático.

2.3 Prática




Imagem 4 - Site Indeed

Na prática resolvi fazer praticamente o mesmo código do desenvolvimento 2.2, mas em um site diferente onde eu pudesse testar o código corretamente, assim quando carregado o programa solicita ao usuário que informe uma habilidade com a qual ele não possui familiaridade. Essa informação é utilizada como critério de filtragem, de modo que vagas que mencionam essa habilidade sejam desconsideradas durante a coleta.

Em seguida, o código acessa a página de vagas, realiza o parsing do HTML e percorre a lista de oportunidades disponíveis. Para cada vaga, são extraídas informações como empresa, localidade e data de publicação. Caso a habilidade informada pelo usuário não esteja presente na descrição da vaga, os dados são armazenados em arquivos de texto individuais dentro da pasta posts.

O programa é executado em um laço de repetição contínuo, realizando novas coletas a cada dez minutos, permitindo a atualização periódica das informações obtidas.

3. Conclusão

A atividade permitiu compreender a aplicação prática do web scraping na coleta de dados para Ciência de Dados, bem como suas limitações. Foi possível observar que o BeautifulSoup é eficiente para a extração de informações em páginas HTML estáticas, porém apresenta restrições em sites que utilizam JavaScript para

carregamento dinâmico de conteúdo. Ao adaptar o código para um site compatível, a coleta e o armazenamento das informações foram realizados com sucesso, reforçando a importância da escolha adequada das ferramentas e das fontes de dados.

Referências

Link do curso - <https://www.youtube.com/watch?v=XVv6mJpFOb0&t=2188s>

Imagem 1 - imagem gerada do site html do curso.

imagem 2 - Feito pelo próprio autor(Usado lucid.app).

Imagem 3 - Site indicado pelo curso -

<https://www.timesjobs.com/job-search?searchType=personalizedSearch&from=submit&searchTextSrc=ft&searchTextText=Python&txtKeywords=Python%2C&txtLocation=&refreshed=true>

Imagem 4 - Site utilizado na prática - <https://br.indeed.com/?r=us>