

Relatório 12 - Prática: Pipelines de Dados I - Airflow (II)

Igor Carvalho Marchi

1. Introdução

O objetivo desta atividade foi compreender os conceitos fundamentais do Apache Airflow, explorando sua arquitetura, componentes e aplicação na automação de pipelines de dados por meio de atividades teóricas e práticas.

2. Desenvolvimento

O Apache Airflow é uma plataforma open source utilizada para criar, agendar, monitorar e gerenciar fluxos de trabalho (workflows) de forma programática. Seu principal objetivo é automatizar processos compostos por múltiplas etapas, garantindo que sejam executados na ordem correta e no momento adequado.

A arquitetura do Airflow é composta principalmente pelos seguintes componentes:

- **Web Server:** interface gráfica utilizada para visualizar e controlar DAGs, tarefas e execuções.
- **Scheduler:** responsável por verificar os agendamentos e disparar as execuções das DAGs.
- **Metadata Database:** banco de dados onde são armazenadas informações sobre DAGs, execuções, logs e configurações.
- **Executor:** componente responsável por definir como as tarefas serão executadas.
- **Workers:** executam efetivamente as tarefas definidas nas DAGs.

DAG (Directed Acyclic Graph)

A Figura 1 apresenta um exemplo de fluxo de dependências entre tarefas, demonstrando como a execução de determinadas atividades depende da conclusão de outras.




Figura 1 – Exemplo de fluxo de dependências em uma DAG.

Uma DAG representa um fluxo de trabalho composto por tarefas e dependências. Ela define a ordem de execução das atividades e não permite ciclos, garantindo que o fluxo siga uma sequência lógica.

Operators

Os Operators representam ações que serão executadas pelo Airflow. Durante o curso foram apresentados diversos operadores, como:

- BashOperator
- PythonOperator
- EmailOperator
- HiveOperator
- SparkSubmitOperator
- SlackAPIPostOperator

Tasks

Uma Task é uma instância de um operador dentro de uma DAG. Cada tarefa possui uma função específica dentro do fluxo de trabalho.

A Figura 2 mostra a visualização de uma DAG no Airflow, permitindo observar a organização das tarefas e suas dependências dentro do workflow.




Figura 2 – Visualização Graph View de uma DAG no Airflow.

Task Instance

Representa a execução de uma tarefa em determinado momento. As Task Instances possuem estados como:

- queued
- running
- success
- failed




Figura 3 – Estados de execução das Task Instances.

DAG Run

Uma DAG Run representa uma execução específica de uma DAG em uma determinada data e horário. Cada execução é independente das demais, permitindo acompanhar o histórico, o estado e os resultados de cada processamento realizado.

Catchup

O Catchup é um mecanismo do Airflow que permite executar automaticamente execuções pendentes de uma DAG referentes a períodos anteriores. Quando habilitado, o Airflow identifica intervalos não processados e agenda suas execuções, garantindo que não haja lacunas no pipeline de dados.

Além dos conceitos teóricos apresentados, foi realizada uma atividade prática para aplicar os conhecimentos adquiridos.

Prática: 10 jogos mais populares da Steam (quantidade de jogadores)

Para a atividade prática, foi criada uma DAG que consulta a API da Steam e obtém os 10 jogos com maior quantidade de jogadores simultâneos na plataforma. O exercício permitiu aplicar os conceitos de DAGs, tarefas e automação de workflows utilizando o Apache Airflow.

3. Conclusão

O Apache Airflow é uma ferramenta muito útil para automatizar pipelines de dados e organizar tarefas que precisam ser executadas em uma ordem específica. Durante as aulas foi possível compreender conceitos importantes como DAGs, operadores, tarefas e agendamento de tarefas. A atividade prática utilizando a API da Steam para obter informações dos 10 jogos mais populares ajudou a consolidar esses conhecimentos, permitindo visualizar na prática o funcionamento do Airflow. De modo geral, a experiência foi positiva e contribuiu para ampliar meus conhecimentos sobre automação e processamento de dados.

Referências

Apache Airflow Documentation: <https://airflow.apache.org/docs/>

Data Camp: <https://www.datacamp.com/pt/blog/what-is-a-dag>

Databricks: <https://www.databricks.com/br/blog/what-is-dag>