

Relatório 13 - Prática: Predição e a Base de Aprendizado de Máquina (II)

Igor Carvalho Marchi

1. Introdução

Durante este conjunto de aulas foram apresentados diversos conceitos importantes relacionados aos modelos preditivos e ao aprendizado de máquina utilizando Python. O conteúdo mostrou como diferentes algoritmos podem ser utilizados para resolver problemas de previsão, classificação e agrupamento de dados, além de explicar em quais situações cada técnica é mais adequada. Além da parte teórica, as atividades práticas permitiram observar como esses modelos funcionam na prática utilizando bibliotecas como o Scikit-Learn.

2. Desenvolvimento

As primeiras aulas abordaram os modelos de regressão. Inicialmente foi apresentada a regressão linear, utilizada para encontrar uma relação entre duas variáveis por meio de uma reta que melhor representa os dados. Esse modelo é bastante utilizado quando se deseja prever valores contínuos, como preços, notas ou vendas futuras. Para ilustrar esse conceito, foi elaborado um exemplo utilizando dados fictícios que relacionam a quilometragem de veículos usados com seu preço de venda. Em seguida foi apresentada a regressão polinomial, que funciona de maneira semelhante, porém permite ajustar curvas aos dados. Essa abordagem consegue representar relações mais complexas, mas também mostrou que utilizar um grau muito elevado pode causar overfitting, fazendo com que o modelo memorize os dados de treinamento e apresente um desempenho inferior quando recebe novos dados.




Figura 1 – Relação entre a quilometragem e o preço de veículos usados. (Autoria própria).

Como mostra a Figura 1, observa-se uma relação inversa entre a quilometragem e o preço do veículo. À medida que a quilometragem aumenta, o valor de mercado tende a diminuir, evidenciando uma tendência linear negativa. Esse exemplo demonstra como a regressão linear pode ser utilizada para estimar valores com base em informações conhecidas.

Em seguida foi apresentada a regressão polinomial, que funciona de maneira semelhante, porém permite ajustar curvas aos dados. Essa abordagem consegue representar relações mais complexas, sendo indicada quando a relação entre as variáveis não pode ser representada adequadamente por uma reta. Entretanto, a utilização de polinômios com grau muito elevado pode causar overfitting, fazendo com que o modelo memorize os dados de treinamento e apresente um desempenho inferior quando aplicado a novos dados.




Figura 2 – Regressão polinomial aplicada à relação entre a quilometragem e o preço de veículos usados. (Autoria própria).

Conforme apresentado na Figura 2, a curva polinomial acompanha de forma mais detalhada o comportamento dos dados quando comparada à regressão linear. Esse tipo de modelo é útil para representar relações não lineares, porém deve ser utilizado com cautela para evitar ajustes excessivos que prejudiquem a capacidade de generalização.

Outro conceito estudado foi a regressão múltipla, que amplia a regressão linear utilizando várias variáveis ao mesmo tempo para realizar uma previsão. O exemplo apresentado durante as aulas utilizava o preço de automóveis, demonstrando que fatores como quilometragem, idade do veículo e outras características influenciam simultaneamente no valor final. Também foram apresentados os modelos multinível, utilizados quando os dados possuem uma

estrutura hierárquica, como alunos pertencentes a escolas ou funcionários pertencentes a empresas. Esse tipo de modelo permite analisar tanto as características individuais quanto as do grupo ao qual cada elemento pertence.




Figura 3 – Exemplo de variáveis utilizadas em um modelo de regressão múltipla. (Autoria própria).

Como ilustrado na Figura 3, a regressão múltipla considera simultaneamente diferentes características do veículo para estimar seu preço. Diferentemente da regressão linear simples, esse modelo avalia a influência conjunta de diversas variáveis, tornando as previsões mais próximas de situações reais.

Na sequência iniciou-se o módulo de Machine Learning com Python, explicando a diferença entre aprendizado supervisionado e não supervisionado. No aprendizado supervisionado os dados utilizados para treinamento já possuem uma resposta conhecida, permitindo que o algoritmo aprenda a realizar previsões ou classificações. Já no aprendizado não supervisionado não existe uma resposta pré-definida, cabendo ao algoritmo identificar padrões e agrupamentos existentes nos dados.

Também foi apresentada a técnica de Train/Test Split, utilizada para dividir o conjunto de dados em treinamento e teste. Essa divisão é importante porque permite avaliar se o modelo realmente aprendeu os padrões presentes nos dados ou apenas decorou os exemplos utilizados durante o treinamento. Esse procedimento foi utilizado durante as atividades para demonstrar como evitar problemas de overfitting.




Figura 4 – Divisão do conjunto de dados em treinamento e teste. (Autoria própria).

Como ilustrado na Figura 4, a divisão entre treinamento e teste permite avaliar o desempenho do modelo em dados que não participaram do processo de aprendizado. Esse procedimento reduz o risco de overfitting e fornece uma avaliação mais confiável da capacidade de generalização do modelo.

Outro algoritmo estudado foi o Naive Bayes, baseado no Teorema de Bayes. Sua principal aplicação apresentada foi na classificação de e-mails como spam ou não spam, utilizando a probabilidade de ocorrência das palavras presentes nas mensagens. Apesar de ser um algoritmo relativamente simples, mostrou-se eficiente para tarefas de classificação de texto.

No estudo sobre aprendizado não supervisionado foi apresentado o algoritmo K-Means, responsável por agrupar dados semelhantes em diferentes clusters. O algoritmo calcula centros para cada grupo e ajusta esses centros até encontrar uma divisão que represente melhor os dados. Como exemplo, foi utilizada a separação de pessoas considerando características como idade e renda.

Em seguida foram apresentados os conceitos de entropia e árvores de decisão. A entropia representa o grau de desorganização dos dados e é utilizada para determinar quais perguntas geram a melhor separação durante a construção da árvore. As árvores de decisão funcionam realizando perguntas sucessivas até chegar a uma classificação final, sendo bastante utilizadas em problemas de previsão por serem simples de interpretar.




Figura 5 – Exemplo simplificado de uma árvore de decisão para auxiliar no processo de contratação de um empregado. (Autoria própria).

Como ilustrado na Figura 5, a árvore de decisão utiliza uma sequência de perguntas para classificar um candidato de acordo com critérios previamente definidos. Nesse exemplo, fatores como experiência profissional, formação acadêmica e desempenho na entrevista são analisados até que seja tomada a

decisão de contratar ou não o candidato. Esse tipo de modelo facilita a interpretação das decisões e pode ser aplicado em diferentes problemas de classificação.




Figura 6 – Representação da redução da entropia durante a separação dos dados. (Autoria própria).

Como ilustrado na Figura 6, a redução da entropia ocorre à medida que os dados são separados em grupos mais homogêneos. Quanto menor a entropia, maior é a organização das informações, facilitando a identificação de padrões e a tomada de decisões durante a construção da árvore.

Outro assunto importante foi o Ensemble Learning, técnica que combina vários modelos para produzir resultados mais precisos. Foram apresentados métodos como Bagging e Boosting, destacando que o primeiro cria diversos modelos independentes e combina suas respostas, enquanto o segundo cria modelos sequencialmente, fazendo com que cada novo modelo tente corrigir os erros do anterior.

Dentro desse contexto foi estudado o XGBoost, um dos algoritmos mais utilizados atualmente em problemas de Machine Learning. Ele utiliza várias árvores de decisão construídas de forma sequencial, buscando melhorar continuamente as previsões e reduzir problemas como o overfitting por meio de técnicas de regularização.

Por fim, foi apresentado o Support Vector Machine (SVM), algoritmo utilizado principalmente para classificação. Seu funcionamento consiste em encontrar a melhor fronteira capaz de separar diferentes classes de dados. Quando os dados não podem ser separados por uma linha reta, o algoritmo utiliza kernels para transformar o espaço dos dados e tornar essa separação possível.

As atividades práticas desenvolvidas ao longo das aulas permitiram aplicar todos esses conceitos utilizando Python. Foi possível criar modelos de regressão, classificação e agrupamento, além de utilizar ferramentas para treinamento, avaliação e comparação de desempenho dos algoritmos. Essas práticas facilitaram a compreensão do funcionamento de cada técnica e mostraram que diferentes problemas exigem diferentes abordagens.

3. Conclusão

As aulas permitiram compreender que o aprendizado de máquina reúne diversas técnicas capazes de solucionar problemas distintos. Enquanto alguns algoritmos são mais indicados para prever valores numéricos, outros são voltados para classificação ou identificação de padrões em conjuntos de dados. Também ficou evidente a importância da preparação dos dados e da avaliação correta dos modelos para evitar resultados enganosos. De maneira geral, o conteúdo contribuiu para ampliar os conhecimentos sobre Machine Learning e mostrou como essas técnicas podem ser aplicadas em situações reais utilizando Python.

REFERÊNCIAS

<https://www.ibm.com/br-pt/think/topics/scikit-learn>

<https://www.ibm.com/br-pt/think/topics/xgboost>

<https://www.ibm.com/br-pt/think/topics/machine-learning>

<https://www.kaggle.com/datasets/abcsds/pokemon?resource=download>