

Relatório 14 - Prática: Redes Neurais (II)

Igor Carvalho Marchi

1. Introdução

O objetivo desta prática foi compreender os fundamentos teóricos e práticos das Redes Neurais Artificiais (RNAs) utilizando a biblioteca TensorFlow/Keras. Durante a atividade foram estudados conceitos como neurônio artificial, funções de ativação, backpropagation, descida do gradiente e técnicas para treinamento de redes neurais. Na parte prática, foi desenvolvido um modelo de rede neural multissaída utilizando um conjunto de dados de partidas do Campeonato Brasileiro, aplicando conceitos de classificação e regressão simultaneamente.

2. Desenvolvimento

2.1 Fundamentação Teórica

As Redes Neurais Artificiais são modelos computacionais inspirados no funcionamento dos neurônios do cérebro humano. Cada neurônio recebe um conjunto de entradas, multiplica essas entradas por pesos, soma um valor chamado bias e aplica uma função de ativação para produzir uma saída.



Durante o treinamento, a rede calcula o erro entre o valor previsto e o valor esperado. Esse erro é propagado para trás por meio do algoritmo Backpropagation, permitindo o ajuste dos pesos através da Descida do Gradiente, com o objetivo de minimizar a função de perda.

Entre as principais funções de ativação estudadas destacam-se:

- **ReLU**, utilizada nas camadas ocultas por proporcionar um treinamento mais eficiente;
- **Sigmoid**, utilizada em problemas de classificação binária;
- **Softmax**, utilizada em problemas de classificação multiclasse;
- **Linear**, utilizada em problemas de regressão.

Função de Ativação	Aplicação	Descrição
ReLU	Camadas ocultas	Utilizada nas camadas ocultas por proporcionar um treinamento mais eficiente, reduzindo o problema do desaparecimento do gradiente e acelerando a convergência da rede.
Sigmoid	Classificação binária	Produz valores entre 0 e 1, representando a probabilidade de um evento ocorrer. É utilizada em problemas de classificação binária, como prever vitória ou derrota.
Softmax	Classificação multiclasse	Converte as saídas da rede em probabilidades para cada classe, sendo utilizada quando existem três ou mais categorias possíveis.
Linear	Regressão	Retorna valores numéricos contínuos, sendo utilizada em problemas de regressão, como a previsão da quantidade de gols marcados em uma partida.

2.2 Modelos Estudados

Durante as aulas foram desenvolvidos diferentes exemplos utilizando redes neurais.

Na base Breast Cancer, foi construída uma rede neural para classificação binária, utilizando a função Sigmoid na camada de saída para identificar tumores benignos ou malignos.

Na base Íris, foi implementado um modelo de classificação multiclasse utilizando a função Softmax para identificar a espécie da flor.

Na base de Carros Usados, foi desenvolvido um modelo de regressão capaz de estimar o preço de venda de um veículo a partir de suas características.

Na base de Videogames, foi utilizada uma rede neural com múltiplas saídas para prever simultaneamente as vendas em diferentes regiões.

Dataset / Problema	Tipo de Tarefa	Arquitetura / Camada de Saída	Função de Perda (Loss)	Tratamento de Dados Aplicado
Breast Cancer	Classificação Binária (Benigno vs. Maligno)	1 neurônio + Ativação Sigmoid	Binary Crossentropy	Padronização de escala com StandardScaler
Iris	Classificação Multiclasse (3 espécies de flores)	3 neurônios + Ativação Softmax	Categorical Crossentropy	Codificação categórica via One-Hot Encoding
Carros Usados	Regressão Simples (Preço do veículo)	1 neurônio + Ativação Linear	Mean Squared Error (MSE)	LabelEncoder, eliminação de nulos e remoção de colunas irrelevantes
Videogames	Regressão Multissaída (Vendas em NA, EU e JP)	3 neurônios + Ativação Linear	MSE individual por saída	Codificação de plataformas/publicadoras e limpeza de duplicados

3. Conclusão

A realização desta prática permitiu compreender, de forma teórica e prática, o funcionamento das Redes Neurais Artificiais. A implementação do modelo utilizando dados do Campeonato Brasileiro demonstrou que uma mesma rede pode resolver diferentes tarefas simultaneamente, realizando classificação e regressão em um único modelo.

Além disso, foi possível observar a importância do pré-processamento dos dados, da normalização das variáveis e da utilização do Dropout para reduzir o overfitting e melhorar a capacidade de generalização da rede.

Referências

Link do documento das aulas:

https://docs.google.com/document/d/1rAvJ0FiWZG5fgecj4VhHqDJcgQWh_O5CrmZCw812GGU/edit?tab=t.0#heading=h.dg3a6zog8i0x

Link dos meus insight visuais:

https://lucid.app/lucidspark/18066335-de30-4eed-9880-54abe681d706/edit?viewport_loc=42231%2C-77%2C4474%2C1988%2C3B0CRSot8otl&invitationId=inv_21f49f9f-9f89-43de-80e8-b16ebb14e097