

## **Relatório 16 - Prática: Redes Neurais Convolucionais 1 (Deep Learning) (II)**

Igor Carvalho Marchi

### **1. Introdução**

Neste card foram apresentados os principais conceitos das Redes Neurais Convolucionais, uma das arquiteturas mais utilizadas em aplicações de Visão Computacional. Durante as aulas foram estudadas as etapas responsáveis pelo processamento de imagens, como convolução, pooling, flattening e camadas densas, além de técnicas utilizadas para melhorar o treinamento dos modelos, como validação cruzada, Batch Normalization, Dropout e Data Augmentation.

### **2. Desenvolvimento**

#### **2.1 Representação de Imagens e Processamento Matricial**

O ponto de partida para o processamento de imagens por algoritmos digitais é a sua conversão em estruturas matriciais. Em imagens dispostas em escala de cinza, a representação ocorre por meio de uma matriz bidimensional (2D), onde cada pixel assume um valor numérico entre 0 (totalmente preto) e 255 (totalmente branco). Já em imagens coloridas, adota-se o sistema RGB, gerando uma estrutura tridimensional (3D) composta por três canais de cor sobrepostos (Vermelho, Verde e Azul).

Para processar essas matrizes sem perder as relações espaciais e a vizinhança entre os pixels, a Rede Neural Convolucional aplica operações matemáticas específicas para extração e redução de atributos

## Operação de Convolução (5x5 para 3x3)

Na etapa de convolução, um filtro matricial de menor dimensão, denominado *kernel*, desliza sobre a imagem original. A cada posição, realiza-se a multiplicação ponto a ponto entre os elementos do filtro e os pixels da imagem, somando-os para gerar uma nova matriz conhecida como mapa de características (*feature map*). No exemplo abaixo, um filtro 3x3 é aplicado sobre uma imagem 5x5, resultando em um mapa de características 3x3:

|   |   |   |   |   |
|---|---|---|---|---|
| 1 | 1 | 1 | 0 | 0 |
| 0 | 1 | 1 | 1 | 0 |
| 0 | 0 | 1 | 1 | 1 |
| 0 | 0 | 1 | 1 | 0 |
| 0 | 1 | 1 | 0 | 0 |

×

|   |   |   |
|---|---|---|
| 1 | 0 | 1 |
| 0 | 1 | 0 |
| 1 | 0 | 1 |

=

|   |   |   |
|---|---|---|
| 4 | 3 | 4 |
| 2 | 4 | 3 |
| 2 | 3 | 4 |

## Operação de Max Pooling (4x4 para 2x2)

Após a convolução e a aplicação da função não linear ReLU para eliminação de valores negativos, aplica-se a etapa de pooling. O método Max Pooling subdivide o mapa de características em pequenas regiões retangulares (por exemplo, 2x2) e extrai exclusivamente o valor máximo de cada quadrante. Esse procedimento reduz a dimensionalidade da imagem em 50%, diminui o custo computacional, confere invariância a pequenas rotações e auxilia no combate ao overfitting:


|    |     |    |    |
|----|-----|----|----|
| 12 | 20  | 30 | 0  |
| 8  | 12  | 2  | 14 |
| 34 | 70  | 37 | 4  |
| 11 | 112 | 25 | 10 |

→

|     |    |
|-----|----|
| 20  | 30 |
| 112 | 37 |

## 2.2 Estrutura e Camadas de uma CNN

Diferentemente das redes neurais densas tradicionais (onde todos os neurônios se conectam integralmente), as CNNs utilizam filtros para identificar automaticamente características espaciais como bordas, curvas, texturas e formas geométricas, reduzindo o número de parâmetros e otimizando o processamento.



O fluxo de dados percorre as seguintes fases:

1. **Operador de Convolução:** Aplica pequenos filtros (kernels) sobre a imagem original para produzir mapas de características (feature maps).
2. **Função de Ativação (ReLU):** Aplicada logo após a convolução para zerar valores negativos e introduzir não linearidade, permitindo que a rede aprenda padrões mais complexos.
3. **Pooling (Subamostragem):** O método MaxPooling divide a matriz em regiões menores e retém apenas o valor máximo de cada uma. Essa etapa reduz a dimensionalidade, preserva os atributos mais relevantes, diminui o custo computacional e evita o overfitting.
4. **Flattening:** Converte os mapas de características multidimensionais em um vetor unidimensional.
5. **Camadas Densas e Softmax:** O vetor entra em uma rede totalmente conectada (Fully Connected), onde a camada final utiliza a função Softmax para calcular a probabilidade de cada classe e gerar a predição.

## 2.3 Otimização e Regularização de Modelos

Para garantir que a rede generalize bem para dados não vistos, foram aplicadas as seguintes técnicas:

- **Batch Normalization:** Normaliza as saídas das camadas intermediárias durante o treinamento, estabilizando o aprendizado e acelerando a convergência.
- **Dropout:** Desativa aleatoriamente uma porcentagem dos neurônios a cada época de treino, impedindo a coadaptação excessiva dos nós e combatendo o overfitting.
- **Validação Cruzada (K-Fold):** Divide o conjunto de dados em K subconjuntos, garantindo que todas as partes sejam utilizadas tanto para treino quanto para validação, resultando em uma métrica de desempenho mais confiável.
- **Data Augmentation:** Aumenta sinteticamente o volume de treino aplicando transformações (rotação, deslocamento, zoom e espelhamento) nas imagens originais, tornando a rede imune a variações de posição e iluminação.

| Técnica             | Finalidade                                     |
|---------------------|------------------------------------------------|
| Conv2D              | Extrair características da imagem              |
| MaxPooling2D        | Reduzir a dimensionalidade                     |
| Flatten             | Converter a matriz em vetor                    |
| Batch Normalization | Estabilizar o treinamento                      |
| Data Augmentation   | Aumentar a variedade de imagens de treinamento |

### 3. Atividade Prática

Na atividade prática foi desenvolvida uma Rede Neural Convolucional (CNN) utilizando a base CIFAR-10 para classificação de imagens. Foram realizados o pré-processamento e a normalização dos dados, seguidos da criação de uma rede com camadas convolucionais, pooling, camada densa e dropout. Após 5 épocas de treinamento com o otimizador Adam, o modelo foi avaliado e obteve aproximadamente 65,22% de acurácia, demonstrando a aplicação das CNNs na classificação de imagens, incluindo a categoria automóvel.

### 4. Conclusão

A realização deste card permitiu consolidar tanto a teoria quanto a implementação prática de Redes Neurais Convolucionais. Ficou evidente que o grande diferencial das CNNs sobre as redes densas tradicionais é a sua capacidade de preservar a topologia espacial das imagens por meio da convolução e do pooling. Além disso, a aplicação combinada de Batch Normalization, Dropout e Data Augmentation provou ser indispensável para a construção de modelos estáveis, precisos e livres de overfitting para aplicações reais de Visão Computacional.

### Referências

**Link do Colors RGB** - [https://www.w3schools.com/colors/colors\\_rgb.asp](https://www.w3schools.com/colors/colors_rgb.asp)

**Link do curso** -

[https://docs.google.com/document/d/1rAvJ0FiWZG5fgecj4VhHqDJcgQWh\\_O5CrmZCw812GGU/edit?tab=t.0#heading=h.2am1k3llzwrj](https://docs.google.com/document/d/1rAvJ0FiWZG5fgecj4VhHqDJcgQWh_O5CrmZCw812GGU/edit?tab=t.0#heading=h.2am1k3llzwrj)

**Link IBM(Informações básicas)** -

<https://www.ibm.com/br-pt/think/topics/convolutional-neural-networks>

**Link da documentação cifar10** -

[https://www.tensorflow.org/api\\_docs/python/tf/keras/datasets/cifar10/load\\_data?utm\\_source=chatgpt.com](https://www.tensorflow.org/api_docs/python/tf/keras/datasets/cifar10/load_data?utm_source=chatgpt.com)

**Link do Insight Visuais** -

[https://lucid.app/lucidspark/18066335-de30-4eed-9880-54abe681d706/edit?view\\_port\\_loc=52203%2C-2776%2C15543%2C6907%2C3B0CRSot8otl&invitationId=inv\\_21f49f9f-9f89-43de-80e8-b16ebb14e097](https://lucid.app/lucidspark/18066335-de30-4eed-9880-54abe681d706/edit?view_port_loc=52203%2C-2776%2C15543%2C6907%2C3B0CRSot8otl&invitationId=inv_21f49f9f-9f89-43de-80e8-b16ebb14e097)

