

Relatório 16 - Prática: Redes Neurais Convolucionais 1 (Deep Learning) (II)

Igor Carvalho Marchi

1. Introdução

Neste card foram apresentados os principais conceitos das Redes Neurais Convolucionais, uma das arquiteturas mais utilizadas em aplicações de Visão Computacional. Durante as aulas foram estudadas as etapas responsáveis pelo processamento de imagens, como convolução, pooling, flattening e camadas densas, além de técnicas utilizadas para melhorar o treinamento dos modelos, como validação cruzada, Batch Normalization, Dropout e Data Augmentation.

2. Desenvolvimento

2.1 Representação de Imagens e Matrizes

O ponto de partida do processamento digital é a representação de imagens por meio de matrizes de pixels:


- **Escala de Cinza:** Cada pixel possui um valor que varia de 0 (cor preta) a 255 (cor branca) em uma única matriz 2D.
- **Imagens Coloridas (RGB):** Cada pixel é formado pela combinação dos três canais de cor (Red, Green, Blue), gerando uma estrutura tridimensional (Altura X largura X 3 (canais)).



Dessa forma, o computador interpreta qualquer imagem como uma matriz numérica, permitindo que os algoritmos de Deep Learning extraíam padrões visuais.

2.2 Estrutura e Camadas de uma CNN

Diferentemente das redes neurais densas tradicionais (onde todos os neurônios se conectam integralmente), as CNNs utilizam filtros para identificar automaticamente características espaciais como bordas, curvas, texturas e formas geométricas, reduzindo o número de parâmetros e otimizando o processamento.



O fluxo de dados percorre as seguintes fases:

1. **Operador de Convolução:** Aplica pequenos filtros (kernels) sobre a imagem original para produzir mapas de características (feature maps).
2. **Função de Ativação (ReLU):** Aplicada logo após a convolução para zerar valores negativos e introduzir não linearidade, permitindo que a rede aprenda padrões mais complexos.
3. **Pooling (Subamostragem):** O método MaxPooling divide a matriz em regiões menores e retém apenas o valor máximo de cada uma. Essa etapa reduz a dimensionalidade, preserva os atributos mais relevantes, diminui o custo computacional e evita o overfitting.
4. **Flattening:** Converte os mapas de características multidimensionais em um vetor unidimensional.
5. **Camadas Densas e Softmax:** O vetor entra em uma rede totalmente conectada (Fully Connected), onde a camada final utiliza a função Softmax para calcular a probabilidade de cada classe e gerar a predição.

2.3 Otimização e Regularização de Modelos

Para garantir que a rede generalize bem para dados não vistos, foram aplicadas as seguintes técnicas:

- **Batch Normalization:** Normaliza as saídas das camadas intermediárias durante o treinamento, estabilizando o aprendizado e acelerando a convergência.
- **Dropout:** Desativa aleatoriamente uma porcentagem dos neurônios a cada época de treino, impedindo a coadaptação excessiva dos nós e combatendo o overfitting.
- **Validação Cruzada (K-Fold):** Divide o conjunto de dados em K subconjuntos, garantindo que todas as partes sejam utilizadas tanto para treino quanto para validação, resultando em uma métrica de desempenho mais confiável.
- **Data Augmentation:** Aumenta sinteticamente o volume de treino aplicando transformações (rotação, deslocamento, zoom e espelhamento) nas imagens originais, tornando a rede imune a variações de posição e iluminação.

Técnica	Finalidade
Conv2D	Extrair características da imagem
MaxPooling2D	Reduzir a dimensionalidade
Flatten	Converter a matriz em vetor
Batch Normalization	Estabilizar o treinamento
Data Augmentation	Aumentar a variedade de imagens de treinamento

3. Atividade Prática

Na atividade prática foi desenvolvida uma Rede Neural Convolucional utilizando a base MNIST para classificação de dígitos manuscritos. Inicialmente foi realizado o pré-processamento das imagens, seguido da construção da arquitetura da rede com camadas convolucionais, pooling, normalização, dropout e camadas densas. Após o treinamento utilizando o otimizador Adam, o modelo foi avaliado no conjunto de testes, obtendo alta acurácia e demonstrando a eficiência das CNNs na classificação de imagens.

4. Conclusão

A realização deste card permitiu consolidar tanto a teoria quanto a implementação prática de Redes Neurais Convolucionais. Ficou evidente que o grande diferencial das CNNs sobre as redes densas tradicionais é a sua capacidade de preservar a topologia espacial das imagens por meio da convolução e do pooling. Além disso, a aplicação combinada de Batch Normalization, Dropout e Data Augmentation provou ser indispensável para a construção de modelos estáveis, precisos e livres de overfitting para aplicações reais de Visão Computacional.

Referências

Link do Colors RGB - https://www.w3schools.com/colors/colors_rgb.asp

Link do curso -

https://docs.google.com/document/d/1rAvJ0FiWZG5fgecj4VhHqDJcgQWh_O5CrmZCw812GGU/edit?tab=t.0#heading=h.2am1k3llzwri

Link IBM(Informações básicas) -

<https://www.ibm.com/br-pt/think/topics/convolutional-neural-networks>