

## Relatório 17 - Prática: Redes Neurais Convolucionais 2 (Deep Learning) (II)


Igor Carvalho Marchi

### 1. Introdução

O Card 17 aborda conceitos relacionados às Redes Neurais Convolucionais (CNNs), aprofundando o funcionamento das convoluções, arquitetura das redes, funções de perda e métodos de otimização. Além disso, são apresentados conceitos de Processamento de Linguagem Natural (NLP), demonstrando como CNNs podem ser utilizadas na classificação de textos. O conteúdo também explora técnicas de treinamento e aprimoramento de modelos, como Batch Normalization, Data Augmentation e o otimizador Adam.

### 2. Desenvolvimento

#### Seção 5: Convolutional Neural Networks (AI Deep Learning)



<fonte: <https://www.dragon1.com/terms/convolutional-neural-networks-definition> >

A convolução matemática é uma operação que combina duas funções para produzir uma terceira, realizando a soma dos produtos entre os valores durante o deslocamento de uma sobre a outra. No contexto de Deep Learning, essa operação é utilizada para identificar padrões nos dados. Os valores dos filtros, como um kernel de tamanho 3×3, não precisam ser definidos manualmente: inicialmente são atribuídos valores e, durante o treinamento, seus parâmetros são ajustados por meio do processo de backpropagation, permitindo que a rede aprenda quais características são mais relevantes.

A utilização do “0-indexing” também possui relação com a forma como os dados são armazenados e acessados computacionalmente, facilitando operações de indexação e manipulação de estruturas como matrizes e tensores.


Em imagens coloridas, os filtros precisam considerar todos os canais de entrada. Assim, em uma imagem RGB, um filtro 3×3 possui profundidade 3, resultando em um bloco 3×3×3, com 27 pesos. A operação considera simultaneamente os três canais de cor para produzir um valor no mapa de características.

## Seção 6: Natural Language Processing (NLP)

No Processamento de Linguagem Natural, os textos precisam ser convertidos para uma representação numérica antes de serem utilizados por uma rede neural. Uma das técnicas estudadas foi o Embedding, que representa cada palavra por um vetor de números. Diferentemente de uma representação one-hot, que gera vetores esparsos e de alta dimensionalidade, o embedding produz representações densas que permitem ao modelo aprender relações entre as palavras.

O pré-processamento envolve a tokenização, responsável por associar palavras a índices numéricos, e o padding, utilizado para padronizar o tamanho das sequências. Depois dessas etapas, a camada Embedding transforma os índices das palavras em vetores que podem ser processados pela rede.


Na aplicação de CNNs para textos, a camada Conv 1D percorre a sequência de palavras e identifica padrões locais. Um filtro com tamanho 3 pode analisar três posições consecutivas da sequência, permitindo identificar combinações de palavras e padrões linguísticos.



## Seção 7: Convolution In-Depth

A convolução não é uma operação exclusiva das redes neurais. Ela também é utilizada tradicionalmente em áreas como processamento de sinais e imagens. No processamento de áudio, por exemplo, a convolução pode ser utilizada para representar o efeito de um ambiente sobre um sinal sonoro. Em processamento de imagens, diferentes filtros podem ser utilizados para produzir efeitos como suavização, nitidez e detecção de bordas.

Outro ponto estudado é a relação entre convolução e frequência. Por meio do Teorema da Convolução, uma convolução realizada no domínio espacial pode ser relacionada a uma multiplicação no domínio da frequência. Essa propriedade permite utilizar técnicas como a Transformada Rápida de Fourier em determinadas situações para tornar operações de convolução mais eficientes.



## Seção 8: Convolutional Neural Network Description

A convolução também pode ser aplicada a dados tridimensionais. Em uma camada Conv3D, o filtro se movimenta por três dimensões do dado de entrada, permitindo trabalhar com informações espaciais e temporais. Esse tipo de operação pode ser aplicado, por exemplo, a volumes tridimensionais ou sequências de imagens.

Outro conceito importante é o campo receptivo. Nas primeiras camadas de uma CNN, os filtros observam regiões pequenas da entrada e podem identificar características simples, como bordas e linhas. Conforme a informação passa por sucessivas camadas convolucionais e de pooling, os neurônios passam a considerar regiões maiores da entrada, permitindo combinar características simples para formar representações mais complexas.

## Seção 9: Practical Tips

O projeto de uma CNN envolve decisões relacionadas à quantidade de filtros, tamanho dos kernels, pooling e profundidade da rede. Uma estratégia comum é aumentar a quantidade de filtros conforme a resolução espacial dos dados diminui. Dessa forma, embora a imagem ou representação fique menor, a rede passa a trabalhar com uma quantidade maior de características.

Outra estratégia estudada é utilizar múltiplas convoluções menores em vez de uma única convolução maior. Por exemplo, duas camadas  $3 \times 3$  podem alcançar um campo receptivo semelhante ao de uma camada  $5 \times 5$ , ao mesmo tempo em que introduzem uma nova função de ativação entre as operações.

## Seção 10: In-Depth: Loss Functions

As funções de perda são responsáveis por medir a diferença entre a previsão realizada pela rede e o resultado esperado. Esse valor é utilizado durante o treinamento para orientar a atualização dos parâmetros.

**Mean Squared Error (MSE):** calcula o erro quadrático médio entre os valores previstos e os valores reais, sendo normalmente associada a problemas de regressão.

**Binary Crossentropy:** é utilizada em problemas de classificação binária, nos quais existem duas possibilidades de saída. A função penaliza principalmente previsões que apresentam alta confiança e estão incorretas.


**Categorical Crossentropy:** é utilizada em problemas de classificação multiclasse. Quando combinada com uma saída Softmax, permite avaliar a probabilidade atribuída pelo modelo às diferentes classes.

## Seção 11: In-Depth: Gradient Descent

O Gradient Descent é um método utilizado para minimizar a função de perda. Durante o treinamento, o algoritmo calcula a direção na qual os parâmetros devem ser ajustados para reduzir o erro.

No Gradient Descent tradicional, o cálculo utiliza todo o conjunto de treinamento antes de realizar uma atualização. Já o Stochastic Gradient Descent (SGD) realiza atualizações utilizando pequenas quantidades de dados, tornando o processo mais frequente.

Também foram estudados conceitos como Momentum, taxas de aprendizado adaptativas e o otimizador Adam. O Momentum utiliza informações das atualizações anteriores para auxiliar na direção do processo de otimização, enquanto métodos adaptativos ajustam a taxa de aprendizado de acordo com o comportamento dos gradientes.



### 3. Aplicação prática

Como aplicação dos conceitos, foi desenvolvida uma CNN para classificação de textos utilizando um conjunto de notícias organizado em um arquivo csv. Os textos passaram por tokenização, padding e embedding antes de serem processados por camadas Conv1D, MaxPooling1D e uma camada de saída com softmax. O treinamento utilizou o otimizador Adam e a função `sparse_categorical_crossentropy`, adequada para três categorias de classificação (Esporte, economia e tecnologia).

### 4. Conclusão

Em conclusão, o conteúdo apresentado aborda os principais conceitos de forma clara e facilita a compreensão sobre as Redes Neurais Convolucionais e suas diferentes técnicas. A parte de Embeddings foi uma das que mais chamou minha atenção, por ser uma técnica importante para trabalhar com textos. Além disso, a parte prática contribui bastante para o aprendizado, pois permite visualizar como os conceitos estudados podem ser aplicados na prática e observar os resultados obtidos pelo modelo.

### Referências

Primeira imagem - <https://www.dragon1.com/terms/convolutional-neural-networks-definition>

links dos insights visuais -

[https://lucid.app/lucidspark/18066335-de30-4eed-9880-54abe681d706/edit?viewport\\_loc=77674%2C-342%2C9896%2C4601%2C3B0CRSot8otl&invitationId=inv\\_21f49f9f-9f89-43de-80e8-b16ebb14e097](https://lucid.app/lucidspark/18066335-de30-4eed-9880-54abe681d706/edit?viewport_loc=77674%2C-342%2C9896%2C4601%2C3B0CRSot8otl&invitationId=inv_21f49f9f-9f89-43de-80e8-b16ebb14e097)

link da aula -

[https://docs.google.com/document/d/1rAvJ0FiWZG5fgecj4VhHqDJcgQWh\\_O5CrmZCw812GGU/edit?tab=t.0#heading=h.8jt4ild682c9](https://docs.google.com/document/d/1rAvJ0FiWZG5fgecj4VhHqDJcgQWh_O5CrmZCw812GGU/edit?tab=t.0#heading=h.8jt4ild682c9)

Sobre CNN - [https://pt.wikipedia.org/wiki/Rede\\_neural\\_convolutacional](https://pt.wikipedia.org/wiki/Rede_neural_convolutacional)