Relatório 26 - Prática: Métricas e Validação de Modelos de Aprendizado de Máquina (III)

Igor Carvalho Marchi

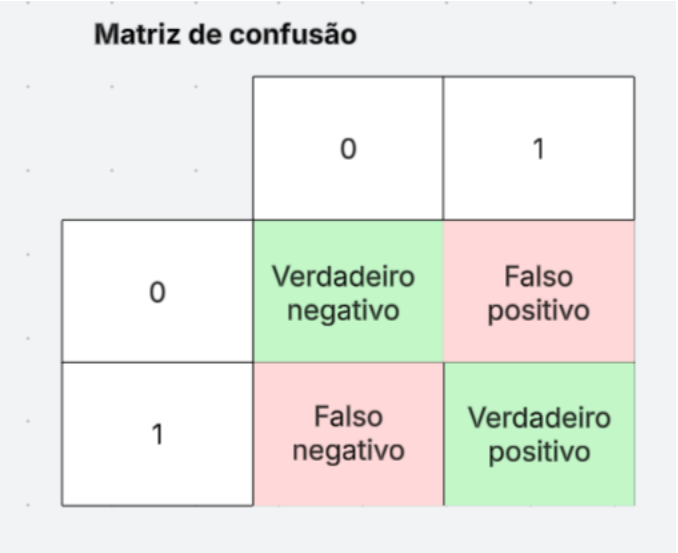
1. Introdução

No card 26 é mostrado como verificar um bom desempenho e entender como o modelo chega às suas decisões. Os dois vídeos deste card tratam dessas etapas. O primeiro apresenta as métricas usadas para avaliar e comparar modelos de classificação, e o segundo apresenta o SHAP, uma técnica para explicar as previsões de modelos que não são interpretáveis por conta própria. Ao final, uma prática curta aplica os conceitos em uma base diferente da usada nas aulas.

2. Desenvolvimento

2.1 Avaliando um modelo de classificação

O vídeo começa separando os dois grandes tipos de problema supervisionado. Na regressão, o modelo prevê um número (o preço de um imóvel, por exemplo); na classificação, prevê uma categoria (fraude ou não fraude, cliente que vai cancelar ou não). O foco da aula é a classificação, e a ideia central é que o desempenho deve ser medido em dados que o modelo não viu no treino, pois são eles que mostram se o modelo aprendeu um padrão ou apenas decorou os exemplos.



A base de todas as métricas é a matriz de confusão, uma tabela que cruza o que realmente aconteceu com o que o modelo previu. Ela gera quatro casos: verdadeiro

positivo (VP), verdadeiro negativo (VN), falso positivo (FP) e falso negativo (FN). Cada métrica combina esses casos para responder a uma pergunta diferente:

Acurácia $\frac{\text{Acertos}}{\text{Total}} = \frac{VN + VP}{VN + FN + VP + FP}$	Precisão $\frac{VP}{VP + FP}$
Especificidade $\frac{VN}{VN + FP}$	Recall $\frac{VP}{VP + FN}$

- **Acurácia:** mostra a proporção de acertos do modelo no total. É a mais fácil de entender, mas só é confiável quando as classes têm tamanhos parecidos. Em uma base com 95% de transações normais, por exemplo, um modelo que diz “não é fraude” para tudo acerta 95% e mesmo assim não serve para nada.
- **Precisão:** mostra, entre os casos que o modelo apontou como positivos, quantos realmente eram. É usada quando um alarme falso custa caro, como bloquear o cartão de um cliente que não fez nada de errado.
- **Recall (sensibilidade):** mostra, entre todos os positivos reais, quantos o modelo conseguiu encontrar. É usada quando deixar um caso passar custa caro, como uma fraude não detectada ou um paciente doente classificado como saudável.
- **Especificidade:** é o recall da classe negativa. Mostra, entre os casos negativos reais, quantos o modelo acertou. É usada quando é importante não classificar errado quem não pertence ao grupo de interesse.

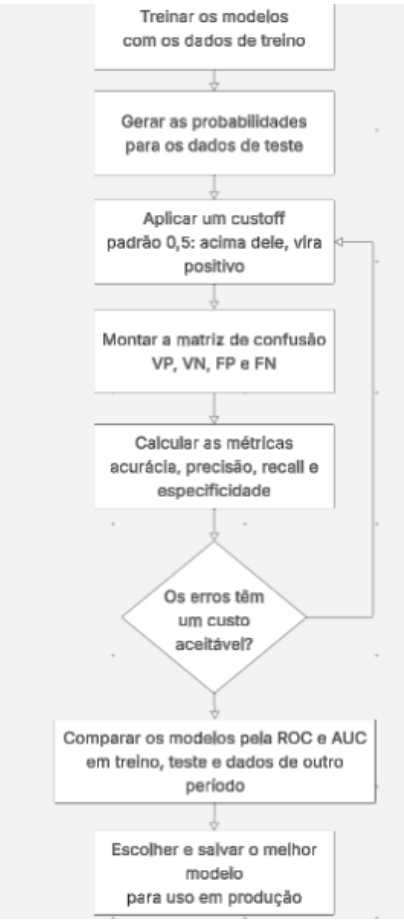
2.2 Limiar de decisão

A maioria dos classificadores não devolve uma classe pronta, mas uma probabilidade. Para transformá-la em classe, é preciso um cutoff: acima dele, o caso vira positivo. O valor comum é 0,5, mas o vídeo mostra que ele pode e deve ser ajustado. Mudar o limiar não muda o modelo, mas muda todas as métricas: um

limiar mais baixo aumenta o recall e diminui a precisão, e um mais alto faz o contrário. O valor ideal depende do custo de cada tipo de erro para o negócio.

2.3 Curva ROC e AUC

Como cada limiar gera uma matriz diferente, a curva ROC resume todos eles em um gráfico: para cada limiar, marca a taxa de falsos positivos no eixo horizontal e o recall no eixo vertical. Uma curva que sobe rápido em direção ao canto superior esquerdo indica um bom modelo, e a diagonal representa um modelo que chuta. A AUC (área sob a curva) transforma isso em um número: 1,0 é perfeito e 0,5 equivale ao acaso. Por não depender de um limiar específico, a AUC é útil para comparar modelos.



2.4 Explicabilidade com SHAP

Uma árvore de decisão pode ser lida regra por regra, mas modelos como o SVC (Support Vector Classifier) não mostram quais características levaram a cada resultado. O SHAP (SHapley Additive exPlanations) resolve isso usando os valores de Shapley da teoria dos jogos: cada característica é tratada como um jogador, e o SHAP calcula quanto cada uma contribuiu para afastar a previsão de um caso da previsão média do modelo.

Para demonstrar, o vídeo treina um LinearSVC com os dados de câncer de mama do scikit-learn, reservando um quinto da base para teste, e o modelo acerta mais de 90% dos casos. Em seguida, cria um shap.KernelExplainer passando a função predict do modelo e uma versão resumida dos dados de treino, gerada com shap.kmeans em 10 grupos. Como esse explicador só observa as entradas e as saídas, ele serve para qualquer tipo de modelo.

Com os valores calculados, o vídeo mostra duas formas de olhar para o modelo. A primeira é a visão geral, feita de duas maneiras: o summary plot mostra, em um único gráfico, quais características mais pesam e se valores altos ou baixos empurram a previsão para um lado ou para o outro; e um ranking calculado com numpy, pela média do módulo dos valores SHAP, ordena as características pelo peso, sem considerar a direção. No exemplo, raio, área e perímetro do tumor ficam no topo. A segunda é a visão de um caso específico, com o force plot, que mostra como cada característica desloca a previsão de um paciente a partir do valor médio do modelo.

Como o KernelExplainer funciona com qualquer modelo, o SHAP pode ser aplicado tanto a um SVC quanto a um Random Forest. Mas é importante lembrar que ele descreve o comportamento do modelo: se uma característica tem peso alto, isso significa que o modelo depende dela, e não que ela seja a causa real do resultado.

3. Prática

Na prática, usei uma base de pacientes com diabetes para prever quais teriam uma piora maior da doença, comparando dois modelos. O Gradient Boosting foi melhor que a Árvore de Decisão, mas os dois se saíram melhor nos dados de treino do que nos de teste. Ao mudar o limiar, o modelo passou a identificar mais pacientes de alto risco, sem que a acurácia mudasse. Com o SHAP, vi que triglicerídeos e IMC altos foram o que mais aumentou o risco previsto.

4. Conclusão

O primeiro vídeo mostra que escolher um modelo exige mais do que olhar a acurácia: é preciso interpretar a matriz de confusão, escolher as métricas e o limiar de acordo com o custo de cada erro e verificar se o modelo generaliza para dados novos. O segundo mostra que, além de medir, é preciso entender o que o modelo faz, tanto no geral quanto em cada previsão. A prática reforçou os dois pontos: a mudança de limiar revelou uma troca que a acurácia escondia, e o SHAP mostrou quais informações mais pesaram nas previsões do modelo.

Referências

YouTube1 - https://www.youtube.com/watch?v=_Y1SWuKr4Tg

YouTube2 - https://www.youtube.com/watch?v=zyXapWWWGG4

Lucidspark - (OBS: Caso a imagem não esteja legível acessar o link abaixo estará nos últimos insights):

https://lucid.app/lucidspark/18066335-de30-4eed-9880-54abe681d706/edit?viewport_loc=283703%2C-12516%2C44256%2C20577%2C3B0CRSot8otI&invitationId=inv_21f49f9f-9f89-43de-80e8-b16ebb14e097